

Cuando «listo» necesita pruebas

Skills, agentes y flujos que dejan evidencia



Una arquitectura para revisar, continuar y defender el trabajo.

**La palabra más peligrosa
de un agente es...**

LISTO.

archivo faltante

ruta rota

evidencia ausente

revisión que nunca corrió

Un resultado plausible todavía puede ser imposible de defender.

CORRECTO

La respuesta coincide con el criterio esperado.

REPRODUCIBLE

Otra persona puede repetir el proceso y obtener el resultado.

TRAZABLE

Podemos reconstruir fuentes, herramientas, versiones y decisiones.

CERRADO

Cumple criterios explícitos y declara lo que quedó pendiente.

La arquitectura organiza el camino entre estos cuatro niveles.

Una arquitectura puede ayudar aunque el modelo no acierte más.

RENDIMIENTO

¿Resuelve más tareas o produce mejores resultados?

EFICIENCIA

¿Usa menos tiempo, tokens o retrabajo?

CONFIABILIDAD

¿Repite el resultado y evita que un error se propague?

AUDITABILIDAD

¿Deja evidencia para revisar, continuar y responder por el trabajo?

En investigación y análisis, ahorrar retrabajo y dejar evidencia puede valer tanto como subir el acierto.

La ayuda de la IA puede cambiar de signo dentro del mismo trabajo.

Experimento aleatorizado con 758 consultores de BCG

18 TAREAS DENTRO DE LA FRONTERA

+12,2%

más tareas
completadas

25,1%

más rápido, con mejor
calidad

1 TAREA FUERA DE LA FRONTERA

-19 pp

en probabilidad de
llegar a la solución
correcta

La unidad de diseño es la tarea concreta, junto con su forma de verificación.


El efecto de una skill cambia mucho entre tareas.

Ganancia promedio en pass rate con skills curadas

SkillsBench



SWE-Skills-Bench



Los estudios prueban entornos distintos.

Juntos muestran que el efecto depende de la tarea, la skill, el verificador y el costo.

Una skill ayuda cuando encaja con la tarea y con el entorno.

2–3

módulos enfocados

lograron más que cargar toda la documentación

16/84

tareas con peor resultado

aun usando una skill curada

39/49

**skills sin mejora
promedio**


en ingeniería de software

**El costo del mal
ajuste**

Una guía incompatible con la versión redujo el pass rate hasta 10 puntos; más contexto también elevó el costo sin mejorar el éxito.

Refinar una biblioteca puede abrir rutas que antes fallaban.

SpreadsheetBench

16%  52%

tareas resueltas con una biblioteca refinada de 22 skills

+28%

mejora relativa frente a skills generadas sin un ciclo de refinamiento

El trabajo estuvo en localizar fallos, elegir la skill adecuada y cubrir rutas de ejecución ausentes.

Una skill conserva cómo se hizo algo que funcionó.

AGENT WORKFLOW MEMORY

+24,6%

éxito relativo en Mind2Web

+51,1% en WebArena y menos pasos en tareas exitosas

AFTER

382

tareas · 6 roles · 22 skills

73,1% de exactitud entre modelos con skills construidas desde trazas diversas

La transferencia tiene límites: una skill puede cruzar de modelo y fallar fuera del rol que la originó.

Cada pieza resuelve un problema distinto.

SKILL

Guía reutilizable con instrucciones, referencias, scripts y archivos.

AGENTE

Sistema que observa, elige el siguiente paso, usa herramientas y se ajusta.

HANDOFF

Registro que transfiere estado y evidencia entre fases o personas.

HARNESS

Entorno que administra herramientas, archivos, permisos, logs y validaciones.

GATE

Control que bloquea el cierre cuando falta evidencia acordada.

Empieza con la pieza más simple que pueda hacer y verificar el trabajo.

Más autonomía

1 LLAMADA

Una respuesta puntual.

2 SKILL

Un método que se repite.

3 FLUJO + GATES

Una secuencia con controles.

4 AGENTE

La ruta se decide al trabajar.

5 MULTIAGENTE

El trabajo puede dividirse.

Cada peldaño añade coordinación, observabilidad y pruebas que también hay que mantener.

El trabajo deja un registro distinto en cada fase.



ID de corrida · huellas de entradas · estado · artefactos · validaciones

Otra persona puede continuar sin reconstruir la conversación.

HANDOFF / REVIEW

fase: revisión
artefactos: outputs/tables/*
validado: 18 controles
pendiente: 2 fuentes
siguiente: conciliar afirmaciones
responsable: finalizador

Evita

intenciones, memoria del intento o un relato optimista del avance

Entrega

estado, evidencia, incertidumbre, bloqueos y próxima acción verificable

La siguiente persona comienza desde un estado comprobable.

Una sola fuente de verdad alimenta todas las superficies de trabajo.

36

skills canónicas

11

colecciones

29 / 7


globales / project-only

6

agentes opcionales

5

schemas



Los enlaces relativos exponen la misma skill sin multiplicar fuentes de verdad.

La estabilidad del camino decide cuánta autonomía hace falta.

USA UNA SKILL

cuando el método es estable, reutilizable y tiene una definición clara de “bien hecho”.

- lista de control reproducible
- comandos o scripts conocidos
- formato y criterios fijos

USA UN AGENTE

cuando el siguiente paso depende de lo que ocurra durante la ejecución.

- exploración abierta
- respuesta del entorno
- recuperación ante errores

Si puedes dibujar la ruta completa por adelantado, la autonomía añade poco.

Ayudan cuando el trabajo puede dividirse de verdad.


Mejor arquitectura multiagente frente a un agente único

Finanzas divisibles



+80,9%

Web dinámica



+9,2%

Planificación
secuencial



-39% a -70%

FACTOR DE PROPAGACIÓN DEL
ERROR

17,2×

agentes independientes
sin verificación cruzada


4,4×

coordinación central
con revisión del orquestador


Otra auditoría: 1.600+ trazas · 7 sistemas · 14 fallos recurrentes

diseño · desalineación · verificación

Cada resultado debería poder volver a sus datos y a su código.



Cada afirmación debería conservar el camino hasta su evidencia.



Ambos flujos comparten cuatro fases y un contrato de evidencia.


FASE	ANÁLISIS DE DATOS	REPORTE / PAPER	EVIDENCIA COMÚN
EXPLORAR	perfil + origen	corpus + mapa de fuentes	entradas + riesgos
EJECUTAR	scripts + modelos	síntesis + borrador	resultados + logs
REVISAR	reproducibilidad	consistencia + citas	hallazgos + controles
FINALIZAR	paquete + huellas	PDF + suplemento + inventario	aceptación + límites

La evaluación debe mirar lo que quedó hecho.

- | | | |
|-------|-------------------------|--|
| 01 | CRITERIO EXTERNO | tests, estado final de una base de datos o criterios de aceptación |
| <hr/> | | |
| 02 | REPETICIÓN | pass ^k y varias corridas para medir consistencia, no una ejecución afortunada |
| <hr/> | | |
| 03 | TRAZABILIDAD | entradas, herramientas, resultados, versiones y huellas vinculados |

Una explicación convincente no compensa un estado final incorrecto.

Una respuesta se vuelve trabajo que otra persona puede revisar.



El juicio mejora cuando puede ver entradas, métodos, desacuerdos y límites.

**Quando las respuestas
están en todas partes,
el juicio se vuelve
el recurso escaso.**

Es lo que lleva una respuesta hasta una decisión digna de confianza.

Literatura y documentación citadas

1. [Dell'Acqua et al. \(2026\). Navigating the Jagged Technological Frontier. Organization Science](#)
2. [Li et al. \(2026\). SkillsBench. arXiv:2602.12670](#)
3. [Han et al. \(2026\). SWE-Skills-Bench. arXiv:2603.15401](#)
4. [Zhong et al. \(2026\). SkillLearnBench. arXiv:2604.20087](#)
5. [Gautam et al. \(2026\). SkillAxe. arXiv:2606.10546](#)
6. [Belikova et al. \(2026\). Managing Procedural Memory. arXiv:2606.23127](#)
7. [Wang et al. \(2024\). Agent Workflow Memory. arXiv:2409.07429](#)
1. [Cemri et al. \(2025\). Why Do Multi-Agent LLM Systems Fail? arXiv:2503.13657](#)
2. [Kim et al. \(2025/26\). Towards a Science of Scaling Agent Systems. arXiv:2512.08296](#)
3. [Yao et al. \(2024\). tau-bench. arXiv:2406.12045](#)
4. [Jimenez et al. \(2024\). SWE-bench. ICLR 2024 / arXiv:2310.06770](#)
5. [Anthropic \(2024\). Building effective agents](#)
6. [OpenAI Developers. Build skills · Customization · Subagents](#)